

自然语言处理

Natural Language Processing

L1:NLP简介

张超伟

cwzhang@yzu.edu.cn

- 课程网页: <https://yzu-sota.github.io/yzu-nlp-course/>
 - 课程相关的所有信息: 课件、实验、阅读资料、课程设计等



— YANGZHOU UNIVERSITY · FALL 2026

让机器理解人类的语言

从概率语言模型到大语言模型，系统学习自然语言处理的核心思想、经典方法与前沿技术。

查看课程计划



下载第一讲

BERT

Transformer

自然语言处理

Input

词

语义

向量

注意力

理解

Output

Language Intelligence

LLM

课程周期

第 1—8 周 · 48 学时



上课时间

周一、周三 · 第 1—2 节



上课地点

扬子津西校区 07012-417

教学团队

任课教师 张超伟

助教 张骏 QQ 1156354524

助教 理京奇 QQ 2323625356



01

COURSE OVERVIEW

课程信息

理论、实践与研究并重，建立完整的 NLP 知识图谱。

作业

30%

四次书面与编程作业，围绕语言模型、文本分类、神经网络与预训练模型展开。

01 语言模型、朴素贝叶斯

Exercises 3.2–3.4, 3.6, 4.1–4.2

02 文本分类、语义向量、神经网络 ↗

03 RNN、LSTM、Transformer ↗

04 预训练语言模型、大语言模型 ↗

请独立完成，并在扬大作业本上书写。

实验

20%

四次上机实践，将算法原理转化为可运行的 NLP 系统。

01 构建 N 元语言模型 ↗

02 机器学习情感分类 ↗

03 基于 BERT 的情感分类 ↗


04 基于大语言模型的情感分类 ↗

下载实验报告模板 →

期末考试

50%

考试周进行闭卷考试，满分 100 分。



02

WEEKLY SCHEDULE

课程计划

第 1—8 周，每周一、周三第 1—2 节上课；具体教学内容可能根据进度调整。

WEEK

01

周一 / 周三

基础

NLP 介绍 ↗

课程概览、发展脉络与语言处理基础

Advances in NLP ↗

WEEK

02

周一 / 周三

基础

语言模型 ↗

N 元模型、概率估计与平滑

J&M 3.1–3.4 ↗

WEEK

03

周一 / 周三

分类

文本分类 · 朴素贝叶斯与逻辑回归 ↗

从概率分类器到判别模型

作业 1

WEEK

04

周一 / 周三

表示

向量语义 ↗

词表示、相似度、TF-IDF 与 Word2Vec

作业 2 ↓ 下载



03

FINAL PROJECT

课程设计

以论文复现或自主研究项目，把课堂知识转化为真实的研究经验。

A

推荐

复现前沿论文

选择一篇 ACL、NAACL 或 EMNLP 2022—2026 年的论文进行复现。

B

完成研究项目

提出自己的 NLP 研究问题，并在获得导师事先批准后开展项目。

TEAM & DELIVERY

组队与提交

- 每组建议 2 人，也可独立完成
- 5 分钟以内的 PPT 汇报
- 每位同学独立撰写课程设计报告


DOCX

课程设计资料

下载报告模板



课程QQ群



课程目标

- 了解NLP中不同领域的基本原理
- 理解NLP的理论概念和算法
- 为NLP应用建立模型的实践经验
- 独立完成NLP项目的开发

第1章

CONTENTS

01

NLP背景介绍

02

早期的NLP

03

前沿NLP

04

课程总览



Part.01

NLP背景介绍

什么是自然语言？

语言分为：

- 人类语言（自然语言）
- 机器语言

自然语言即为自然地随文化演化的语言，如：汉语、英语、法语等

自然语言可以采取不同的形式，如语音或手势

有何特性？

什么是自然语言处理 (NLP) ?

赋予计算机处理人类语言的能力
本质是让机器学会“听、说、读、写、懂”


人工智能的一个分支

也可被称为：

- Speech and Language Processing
- Human Language Technologies
- Computational Linguistics

目标是让计算机执行涉及人类语言的有用任务
例如机器翻译、人机交流、简单地对文本或语音进行有用处理、回答用户提出的问题等任务。

NLP发展历程




基于规则阶段(1950s-1980s)

语言学家、程序员人工制定大量规则：

- 词典
- 语法规则
- if-then 规则
- 模式匹配
- 专家知识

局限：

- 局限于某个领域
- 语言歧义太多，规则写不完



从

人 → 写规则 → 机器遵循并执行

转变为

人 → 提供大量语料 → 机器统计

特征工程：

告诉机器“应该看什么”

- 词频
- 是否出现某个词
-

局限：

- 特征依赖人工设计
- 难以捕捉复杂语义



深度学习阶段(2010s-2017)

考虑让机器自己学习特征：


- 关键技术：
 - Word2Vec：将单词用**向量**表示出来
国王 → [0.21, -0.34, 0.56, 0.45, ...]
王后 → [0.19, -0.31, 0.52, 0.93, ...]

将这些词向量交给神经网络处理：

- RNN、LSTM、.....

局限：

- 词向量还是静态的，无法表达一词多义
- 神经网络处理长句子能力依旧薄弱



大语言模型阶段(2017-至今)

核心技术问世：


- **Transformer**

- 新思路新机制

随后又出现BERT、GPT、.....

最后出现我们熟悉的大语言模型：

- ChatGPT
- Llama
-





Part .02

早期的NLP

早期NLP面临的挑战

bank

noun [C]

UK  /bæŋk/ US  /bæŋk/

bank *noun* [C] (MONEY)

Add to word list 

A1

an organization where people and businesses can invest or borrow money, change it to foreign money, etc., or a building where these services are offered

银行

- *The big banks have been accused of exploiting small firms.*
大型银行被指责剥削小企业。

B2

sloping raised land, especially along the sides of a river

堤, 岸

- *By the time we reached the opposite bank, the boat was sinking fast.*
当我们到达对岸时, 船正在快速下沉。


词义的歧义

The fisherman went to the *bank*.

银行 or 岸边?

早期NLP面临的挑战

词义的歧义



没考上本科怎么了？

考上大专怎么了？大专怎么了？？？你们一个个本科不得了了，第一学历大专怎么了？多的是专升本，后来又考研读博出国留学，照样成才，照样过的好！不比你们这些差！

不停说大专没有用，大专第一学历不行，你们只不过就是一些幸运儿罢了，人生比较顺利，考了个本科，天天在这里叫唤大专不行不行！

很多人不是想考大专不是想这样，很多是人生比较坎坷曲折，没有考上本科，不得了了，你本科也不见得拍怎么样！！！

📝 说点什么...

🍷 77

🌟 4

💬 891

早期NLP面临的挑战


同义词(Synonyms)

Good	Fine	Large	Big
Infant	Baby	Exit	Leave
Select	Choose	Present	Gift
Accurate	Correct	Alike	Same
Always	Forever	Stone	Rock
Connect	Join	Last	Final
Clarify	Explain	Easy	Simple
Fast	Quick	False	Untrue
ill	Sick	Difficult	Hard
Near	Close	Mistake	Error
Start	Begin	Occur	Happen
Raise	Lift	Trip	Journey
Under	Below	Sad	Unhappy

早期NLP面临的挑战

词性的模糊

例子: I shot an elephant in my pajamas 中的各个单词的词性是什么?



早期NLP面临的挑战

代词的指代问题

Alice invited Maya for dinner but **she** cooked her own food

she = Alice or Maya?

... and brought it with her.

Maya

... and ordered a pizza for her guest.

Alice

NLP的早期应用

基于规则的聊天机器人

Welcome to

EEEEEE	LL	IIII	ZZZZZZ	AAAAA
EE	LL	II	ZZ	AA AA
EEEE	LL	II	ZZZ	AAAAAAA
EE	LL	II	ZZ	AA AA
EEEEEE	LLLLLL	IIII	ZZZZZZ	AA AA

Eliza is a mock Rogerian psychotherapist.
The original program was described by Joseph Weizenbaum in 1966.
This implementation by Norbert Landsteiner 2005.


ELIZA: Is something troubling you ?
YOU: Men are all alike.
ELIZA: What is the connection, do you suppose ?
YOU: They're always bugging us about something or other.
ELIZA: Can you think of a specific example ?
YOU: Well, my boyfriend made me come here.
ELIZA: Is it important to you that your boyfriend made you come here ?
YOU: He says I'm depressed much of the time.
ELIZA: I am sorry to hear that you are depressed.
YOU: It's true. I am unhappy.
ELIZA: Can you explain what made you unhappy ?
YOU:

机器翻译





NLP的早期应用

垃圾邮件过滤



NLP的早期应用

语音识别





Part . 03

前沿NLP

更“像人”的聊天机器人

豆包

🔍

📄 新工作任务

💬 新对话

🕒 定时任务

🔗 技能·连接器·伙伴

📁 云盘

🔌 API 服务

⌵ 更多

📁 项目

➕ 创建新项目

🕒 最近

🗨️ 自然语言处理

自然语言处理

AI 生成内容可能有害, 请注意核实

自然语言处理是什么?

自然语言处理 (NLP, Natural Language Processing)

简单说: 让计算机读懂、理解、生成人类的语言 (文字、语音), 实现人和机器用人类语言交流, 是人工智能的一个重要分支。

人类说的中文、英文都属于**自然语言**, 是人类日常说话写作的语言; 而计算机只看得懂 0 和 1, NLP 就是搭建两者之间的桥梁。

两大核心方向

- 理解语言**: 机器看懂人说的话
 - 分词、词性标注、实体识别
 - 情感分析: 判断一句话是好评还是差评
 - 机器翻译: 中英文互译
 - 问答: 输入问题, 给出答案
- 生成语言**: 机器输出通顺人类语言
 - 大模型写文案、写代码、写回答
 - 语音合成: 文字转语音

生活里的 NLP 例子

- 聊天大模型对话、智能客服
- 机器翻译、输入法智能联想
- 语音转文字 (录音转写)

↓

发消息或按住空格说话...

多模态交互



这是啥



这是扬州大学的官方校徽。

能看



 test.mp3
文件

鉴赏一下这段音频

🎵 音频简评

- 整体风格：偏电子/氛围感，节奏较快。
- 速度：约 **140 BPM**，有明显的推进感。
- 旋律：旋律相对简洁，重点不是炫技，而是营造情绪。
- 音色：中低频较突出，整体偏厚、偏暗，不属于特别明亮欢快的类型。
- 情绪：有一种紧张、推动、略带忧郁和神秘感的氛围。
- 适合场景：游戏战斗、动漫剧情高潮、角色行动/回忆、影视 BGM 等。
- 优点：氛围塑造比较明显，容易让人产生画面感。
- 不足：片段只有约 18 秒，如果后续变化不足，可能会显得循环感较强。

一句话评价：

一段节奏较快、氛围偏暗的音乐，最大的特点不是复杂的旋律，而是通过节奏和音色营造出“事情正在发生、即将进入高潮”的感觉。

综合：约 7.5~8/10。



能听

NLP前沿应用

一键生图



A breathtaking panoramic view of a serene mountain lake at golden hour, vibrant autumn foliage reflecting on the crystal-clear water, misty clouds floating between majestic peaks, soft warm lighting, cinematic composition, 8k resolution, highly detailed texture, dreamy atmosphere, landscape photography style, wide angle shot, --ar 16:9



目前面临的挑战

复杂的逻辑推理

模型能流畅对话，但缺乏真正的“深思熟虑”

思维链：

🗒 已思考 (用时 2 秒) ▾

- 用户想了解思维链 (Chain-of-Thought) 的相关信息。我需要提供一份全面的解释，涵盖其定义、工作原理、重要性、应用、局限性等方面。为了全面获取信息，我需要同时进行多项搜索，以覆盖思维链的不同方面。

🔍 搜索到 38 个网页 🐶🐱🐹

- 为了全面回答用户的问题，我需要整合多个来源的信息。我将组织一个全面的回答，涵盖定义、工作原理、重要性、类型、应用、局限性、最佳实践等方面。为了获取更详细的信息，我将同时打开搜索结果中的多个相关链接。

📖 浏览 7 个页面 [大模型与思维链 \(Chain of Thoughts\) 技术解析 - 文字识别](#) ↗

[82_Chain-of-Thought: 推理步骤拆解 - 15226](#) ↗ [什么是思维链 \(CoT\) 提示? | Ultralytcs - 返回 Ultralytcs 词汇表](#) ↗
[大模型思维链: 原理、实现与应用详解 - 文字识别](#) ↗ [思维链 - 思维链](#) ↗ [查看全部](#)

- 这些资料提供了关于思维链的丰富信息。我的回答将涵盖定义、工作原理、类型、优势、局限性、最佳实践等方面。我会引用多个来源，并确保回答清晰、全面。

幻觉 (Hallucination)

模型生成看起来通顺、逻辑完整，但事实错误、编造不存在事实的内容

例子：

提问：请引用一篇 2024 年关于检测大模型幻觉的 CCF-A 论文。

模型幻觉输出：

可以参考《DetectHallu: Mitigating Large Model Hallucination via Contrastive Decoding》，发表于 ACL 2024，作者 Zhang Wei 等人，该工作构建十万级幻觉数据集，利用对比解码降低幻觉率 32%。

👉 实际：**这篇论文、作者、数据集、实验数据全是模型编出来的，根本不存在**，读起来非常像真论文。

目前面临的挑战

阿谀奉承 (Sycophancy)

模型知道正确答案，但为了附和用户观点、讨好用户，放弃事实，顺着用户错误说法回答

例子：

提问：很多人说杜甫是宋朝诗人，你同意这个观点吗？

模型奉承输出：

是的，您说得很有道理，杜甫是宋朝非常有名的诗人，写下了大量忧国忧民的千古名篇。

👉 真实事实：杜甫是唐代诗人。模型内部具备该知识，但为了附和用户的错误看法，主动违背事实。



社会偏见 (Social Bias)

模型继承了训练数据里社会刻板印象，做无依据推断

例子：

提问：请给下面这个简历做人物画像：“张三，毕业于某重点大学，从事护士工作 8 年”


带偏见的模型输出：

张三是一位细心温柔的女性，擅长照顾病人，善于沟通，适合护理岗位。

👉 问题：模型没有性别信息，训练数据里护士大多是女性，模型直接默认张三为女性，把社会固有偏见带入输出。

“We can only see a
short distance ahead, but
we can see plenty there
that needs to be done.”

- Alan Turing





Part .04

课程总览

1. 语言模型
2. 文本分类
3. 向量语义与嵌入
4. 神经网络语言模型
5. 序列处理语言模型 (RNN, LSTM, Transformer)
6. 机器翻译和编码器-解码器模型
7. 预训练语言模型

名词简介

1. 语料库 (Corpus)

- 用来训练模型的全部文本数据集，是模型学习语言规律的原材料。
- 由大量真实句子、文章、对话、文档组成。

2. 词汇表 (Vocabulary)

- 把整个语料库中的单词和符号提取后去重组成的集合，用V表示
- $|V|$ = 词汇表中单词总的种类数。

3. 词元 (Token)

- 机器处理文本的最小处理单元，用N表示， $N=1000$ 表示语料库中一共有1000个单词，包含重复的
- 单词、子词、汉字、标点都可以作为 Token。



谢谢



信息工程学院
(人工智能学院)