

自然语言处理

Natural Language Processing

L3:文本分类

第3章

CONTENTS

01

朴素贝叶斯分类器

02

训练朴素贝叶斯分类器

03

朴素贝叶斯实例

04

二分类评估

05

逻辑回归

文本分类任务

垃圾邮件识别

匿名作者识别

文章主题识别

电影评论分类

.....

还有哪些？

情感分析(Sentiment Analysis)

为什么要情感分析？

电影是否好看？

产品是否好用？

社交媒体评论？

市场规律预测？

情感分析(Sentiment Analysis)

情感 emotion: 对事件的当下感受和评价

- angry, sad, joyful, fearful, ashamed, proud, elated

情绪 mood: 有弥漫性并且具有低强度长时间的主观感受

- cheerful, gloomy, irritable, listless, depressed, buoyant

人际立场 interpersonal stances: 与他人进行互动时的情感立场

- friendly, flirtatious, distant, cold, warm, supportive, contemptuous

态度 attitude: 持久且带情感色彩的信念, 或对人对事的情感倾向

- liking, loving, hating, valuing, desiring

人格特质 Personality traits: 稳定的人格倾向和行为倾向

- nervous, anxious, reckless, morose, hostile, jealous

文本分类任务的定义

输入:

- 一个完整的文本 d
- 一个集合 $C=\{c_1, c_2, \dots, c_n\}$, 其中每一个元素都是一种分类

输出:

- 一个预测出的分类 $c_i \in C$

分类方法：hand-crafted 规则

hand-crafted规则：手动地通过人工预先设置规则(特征)

使用单词的一些组合或者其他特征作为规则，比如：

- 垃圾邮件识别 – 黑名单邮箱地址或者(“dollars” AND “you have been selected”)

识别的准确率可以很高

- 若由相关领域的专家仔细地定义专门的识别规则

但建立和维持这些规则成本很高

- 为什么？

分类方法：有监督的机器学习

输入:

- 一个完整的文本 d
- 一个集合 $C=\{c_1, c_2, \dots, c_n\}$, 其中每一个元素都是一种分类
- 一个拥有 m 份人工标注文档构成的训练集, 形式为 $(d_1, c_1), \dots, (d_m, c_m)$ 即 “文本-类别标签” 的数据对

输出:

- 一个经过训练得到的分类器 $\gamma: d \rightarrow c$

分类方法：有监督的机器学习

- 分类器
 - 朴素贝叶斯 Naïve Bayes
 - 逻辑回归 Logistic regression
 - 神经网络 Neural networks
 - K近邻 k-Nearest Neighbors
 - ...



Part.01

朴素贝叶斯分类器

什么是朴素贝叶斯分类器

基于贝叶斯规则的简易（朴素 或 naive）分类方法

依赖于较为简单的文本表达：

- 词袋 bag of words

词袋表达

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!



it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1
...	...

词袋表达

$$Y(\begin{array}{|c|c|} \hline \text{seen} & 2 \\ \hline \text{sweet} & 1 \\ \hline \text{whimsical} & 1 \\ \hline \text{recommend} & 1 \\ \hline \text{happy} & 1 \\ \hline \dots & \dots \\ \hline \end{array}) = C$$


在文档和类别中使用贝叶斯规则

- 文档 d and 类别 c

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$

朴素贝叶斯分类器

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$

$$c_{MAP} = \operatorname{argmax}_{c \in C} P(c | d)$$

MAP 指的是“后验概率最大化” = 最有可能的类

$$= \operatorname{argmax}_{c \in C} \frac{P(d | c)P(c)}{P(d)}$$

贝叶斯规则

$$= \operatorname{argmax}_{c \in C} P(d | c)P(c)$$

去掉分母

朴素贝叶斯分类器

“似然值”

“先验概率”

$$c_{MAP} = \operatorname{argmax}_{c \in C} P(d | c) P(c)$$

$$= \operatorname{argmax}_{c \in C} P(x_1, x_2, \dots, x_n | c) P(c)$$

使用 $x_1 \dots x_n$ 代表文件d

朴素贝叶斯分类器

$$c_{MAP} = \operatorname{argmax}_{c \in C} P(x_1, x_2, \dots, x_n | c) P(c)$$

$|X|^n \cdot |C|$ 个参数

当训练样本足够大时, 才可以被估计

朴素贝叶斯独立假设

$$P(x_1, x_2, \dots, x_n \mid c)$$

词袋假设：假设不考虑单词的位置

条件独立假设：在给定类型c时，假设特征概率 $P(x_i \mid c_j)$ 是独立的

$$P(x_1, \dots, x_n \mid c) = P(x_1 \mid c)P(x_2 \mid c)P(x_3 \mid c) \dots P(x_n \mid c)$$

多项式朴素贝叶斯分类器

$$c_{MAP} = \operatorname{argmax}_{c \in C} P(x_1, x_2, \dots, x_n | c) P(c)$$

$$c_{NB} = \operatorname{argmax}_{c \in C} P(c) \prod_{x \in X} P(x | c)$$

使用多项式朴素贝叶斯分类器进行文本分类

positions $\leftarrow$ all word positions in test document

$$c_{NB} = \operatorname{argmax}_{c_j \in C} P(c_j) \prod_{i \in \text{positions}} P(x_i | c_j)$$

多个概率相乘时会出现的问题

$$c_{NB} = \operatorname{argmax}_{c_j \in C} \prod_{i \in \text{positions}} P(x_i | c_j)$$

当有许多概率相乘时，结果会无限趋近于零(浮点下溢)

有什么方法？

使用对数函数log，因为 $\log(ab) = \log(a) + \log(b)$

也就是将概率相乘转化为概率相加

原分类器

$$c_{NB} = \operatorname{argmax}_{c_j \in C} P(c_j) \prod_{i \in \text{positions}} P(x_i | c_j)$$

使用对数函数后的分类器

$$c_{NB} = \operatorname{argmax}_{c_j \in C} \left[\log P(c_j) + \sum_{i \in \text{positions}} \log P(x_i | c_j) \right]$$

注意：

- 1): 使用对数函数后，不会改变原有的类别排序
 - 有最高概率的类别依旧具有最高对数概率的性质
- 2): 线性模型
 - 因为将所有权重进行了相加操作，因此朴素贝叶斯模型是线性的



Part.02

训练朴素贝叶斯分类器

训练朴素贝叶斯分类器

$$C_{NB} = \operatorname{argmax}_{c_j \in \mathcal{C}} [\log P(c_j) + \sum_{i \in \text{positions}} \log P(w_i | c_j)]$$

使用最大似然估计:

- 使用数据中的频率统计

$$\hat{P}(c_j) = \frac{\overset{\text{类}c_j\text{的计数}}{N_{c_j}}}{\underset{\text{所有文档的计数}}{N_{total}}}$$

$$\hat{P}(w_i | c_j) = \frac{\text{count}(w_i, c_j)}{\sum_{w \in V} \text{count}(w, c_j)}$$

训练朴素贝叶斯分类器

$$\hat{P}(w_i | c_j) = \frac{\text{count}(w_i, c_j)}{\sum_{w \in V} \text{count}(w, c_j)}$$

在有关话题 c_j 的文档中,
单词 w_i 出现是次数与所有单词的比例

整合所有分类为 c_j 的文档为一个大型文档库

- 使用单词 w 在文档库中的频率

最大似然估计的问题

假设某个训练文档没有出现单词 fantastic, 但被分类为positive 类, 该怎么办?

$$\hat{P}(\text{"fantastic"} | \text{positive}) = \frac{\text{count}(\text{"fantastic"}, \text{positive})}{\sum_{w \in V} \text{count}(w, \text{positive})} = 0$$

无论其他证据如何, 都不能以零概率为条件!

$$c_{MAP} = \operatorname{argmax}_c \hat{P}(c) \prod_i \hat{P}(x_i | c)$$

朴素贝叶斯+拉普拉斯平滑

$$\hat{P}(w_i | c) = \frac{\text{count}(w_i, c) + 1}{\sum_{w \in V} (\text{count}(w, c) + 1)}$$

$$= \frac{\text{count}(w_i, c) + 1}{\sum_{w \in V} \text{count}(w, c) + |V|}$$

多项式朴素贝叶斯训练

从训练语料库中，提取词汇表(*Vocabulary*)

$Text_j$ 代表所有属于 c_j 分类的文档集合

- Calculate $P(c_j)$ terms
 - For each c_j in C do
 - $docs_j \leftarrow$ all docs with class $= c_j$
- Calculate $P(w_k | c_j)$ terms
 - $Text_j \leftarrow$ single doc containing all $docs_j$
 - For each word w_k in *Vocabulary*
 - $n_k \leftarrow$ # of occurrences of w_k in $Text_j$

$$P(w_k | c_j) \propto \frac{n_k + \alpha}{n + \alpha |Vocabulary|}$$

未知单词(unknown words)

什么是未知单词?

- 没有出现在训练集和收集的词汇表中
- 但出现在测试集中

如何解决?

- 忽视它们? 如何做?
 - 从测试集中删除
 - 假设不存在
 - 不分配概率给这些单词

停用词(stop words)

很多模型都会设置一些停用词
即这些词虽然在词汇表中,但我们依然会忽略它们

- 比如 the 和 a,显然这些单词出现评论很高,但几乎没有任何特征信息
- 如何去除这些停用词?
 - 按照单词频率从高到低排序词汇表
 - 将前10或前50最高频率的单词列入停用词表
 - 从训练集和测试集中删除这些单词

然而去除停用词实际上并不能提高模型性能

- 朴素贝叶斯模型使用所有单词,并不会忽视停顿词

简述朴素贝叶斯训练算法过程

```
function TRAIN NAIVE BAYES(D, C) returns  $\log P(c)$  and  $\log P(w|c)$ 

for each class  $c \in C$                                 # Calculate  $P(c)$  terms
     $N_{doc}$  = number of documents in D
     $N_c$  = number of documents from D in class  $c$ 
     $\text{logprior}[c] \leftarrow \log \frac{N_c}{N_{doc}}$ 
     $V \leftarrow$  vocabulary of D
     $\text{bigdoc}[c] \leftarrow$  append(d) for  $d \in D$  with class  $c$ 
    for each word  $w$  in  $V$                                 # Calculate  $P(w|c)$  terms
         $\text{count}(w, c) \leftarrow$  # of occurrences of  $w$  in  $\text{bigdoc}[c]$ 
         $\text{loglikelihood}[w, c] \leftarrow \log \frac{\text{count}(w, c) + 1}{\sum_{w' \in V} (\text{count}(w', c) + 1)}$ 
return  $\text{logprior}$ ,  $\text{loglikelihood}$ ,  $V$ 
```

简述朴素贝叶斯训练算法过程

N_{doc} = number of documents in D

N_c = number of documents from D in class c

$$\text{logprior}[c] \leftarrow \log \frac{N_c}{N_{doc}}$$

统计每一种文章的个数 N_c , 以及所有文章的个数 N_{doc}
计算出每一种类别的 $P(c_j)$ 放入数组logprior[]

$V \leftarrow$ vocabulary of D

$\text{bigdoc}[c] \leftarrow \text{append}(d)$ for $d \in D$ with class c

将所有文档中出现的单词种类作为词汇表 V
将每一类的所有文章拼接成一个大文章放入bigdoc数组

for each word w in V # Calculate $P(w|c)$ terms

$\text{count}(w, c) \leftarrow$ # of occurrences of w in $\text{bigdoc}[c]$

$$\text{loglikelihood}[w, c] \leftarrow \log \frac{\text{count}(w, c) + 1}{\sum_{w' \text{ in } V} (\text{count}(w', c) + 1)}$$

先数出 C 类中 W 单词出现的总次数为 $\text{count}(w, c)$
通过公式计算出 $P(w|c)$ 的似然, 循环操作每一个单词
将每一个类别的每一个单词的概率放入loglikelihood数组中



Part.03

朴素贝叶斯实例

朴素贝叶斯用于二分类情感分类任务

	Cat	Documents
Training	-	just plain boring
	-	entirely predictable and lacks energy
	-	no surprises and very few laughs
	+	very powerful
	+	the most fun film of the summer
Test	?	predictable with no fun

朴素贝叶斯用于二分类情感分类任务

	Cat	Documents
Training	-	just plain boring
	-	entirely predictable and lacks energy
	-	no surprises and very few laughs
	+	very powerful
	+	the most fun film of the summer
Test	?	predictable with no fun

1. 先验概率计算:

$$\hat{P}(c_j) = \frac{N_{c_j}}{N_{total}} \quad P(+) = \frac{2}{5}$$

$$P(-) = \frac{3}{5}$$

2.

去除“with” 因为训练集中没有出现这个单词

3. 训练集中的最大似然计算:

$$p(w_i|c) = \frac{\text{count}(w_i, c) + 1}{(\sum_{w \in V} \text{count}(w, c)) + |V|}$$

$$P(\text{“predictable”}|-) = \frac{1+1}{14+20} \quad P(\text{“predictable”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“no”}|-) = \frac{1+1}{14+20} \quad P(\text{“no”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“fun”}|-) = \frac{0+1}{14+20} \quad P(\text{“fun”}|+) = \frac{1+1}{9+20}$$

4. 对测试数据进行估计(后验概率计算):

$$P(-)P(S|-) = \frac{3}{5} \times \frac{2 \times 2 \times 1}{34^3} = 6.1 \times 10^{-5}$$

$$P(+)P(S|+) = \frac{2}{5} \times \frac{1 \times 1 \times 2}{29^3} = 3.2 \times 10^{-5}$$

优化情感分类任务

在情感分析任务中，一个单词是否出现比这个单词的出现频率更加重要

- 单词 fantastic 出现一次即可以提供信息
- 单词 fact 出现四次没有提供太多信息

二进制情感分类(非1即0)

- 将单词计数限制为1
- 不同于伯努利朴素贝叶斯

二元多项朴素贝叶斯：学习

- Calculate $P(c_j)$ terms
 - For each c_j in C do
 $docs_j \leftarrow$ all docs with class $= c_j$
- Calculate $P(w_k | c_j)$ terms
 - Remove duplicates in each doc:
 - For each word type w in doc_j
 - Retain only a single instance of w

$$P(w_k | c_j) \propto \frac{n_k + \alpha}{n + \alpha |Vocabulary|}$$

- $Text_j \leftarrow$ single doc containing all $docs_j$
- For each word w_k in $Vocabulary$
 $n_k \leftarrow$ # of occurrences of w_k in $Text_j$

优化情感分类任务

Four original documents:

- it was pathetic the worst part was the boxing scenes
- no plot twists or great scenes
- + and satire and great plot twists
- + great scenes great film

After per-document binarization:

- it was pathetic the worst part boxing scenes
- no plot twists or great scenes
- + and satire great plot twists
- + great scenes film

	NB Counts		Binary Counts	
	+	–	+	–
and	2	0	1	0
boxing	0	1	0	1
film	1	0	1	0
great	3	1	2	1
it	0	1	0	1
no	0	1	0	1
or	0	1	0	1
part	0	1	0	1
pathetic	0	1	0	1
plot	1	1	1	1
satire	1	0	1	0
scenes	1	2	1	2
the	0	2	0	1
twists	1	1	1	1
was	0	2	0	1
worst	0	1	0	1

计数可以大于1! 二进制发生在单个文档中

情感分类：应对否定

I really like this movie

I really **don't** like this movie

don't 否定词的加入使得原本正面的句子变为负面的

同样消极的也可以被修饰为积极的：

Don't dismiss this film

Doesn't let us get bored

情感分类：应对否定

情感分析中一种常用的简单方法：

一旦出现否定词，在之后的每一个单词后添加 **NOT_** 前缀直到下一个标点：

didn't like this movie , but I



didn't **NOT_**like **NOT_**this **NOT_**movie , but I

情感分类：词典(Lexicons)

很多时候没有充足的训练数据集

在这种情况下，可以使用预先建立的词列表-**Lexicons**

有很多公开发布的词典

MPQA 主观意向词典

Theresa Wilson, Janyce Wiebe, and Paul Hoffmann (2005). Recognizing Contextual Polarity in Phrase-Level Sentiment Analysis. Proc. of HLT-EMNLP-2005.

Riloff and Wiebe (2003). Learning extraction patterns for subjective expressions. EMNLP-2003.

- 主页: https://mpqa.cs.pitt.edu/lexicons/subj_lexicon/
- 从8221个词根衍生出的6885 个词汇, 并且标记有强度(strong/weak)
- 2718 positive 正面的
- 4912 negative 负面的
- 其中一些词汇:
 - + : admirable, beautiful, confident, dazzling, ecstatic, favor, glee, great
 - : awful, bad, bias, catastrophe, cheat, deny, envious, foul, harsh, hate

情感分类中使用情感词典

添加一项特征，即当一个单词出现在词典中那么获取一个计数

例如：

特征 1：文本里「出现任意积极情感词」的总次数

特征 2：文本里「出现任意消极情感词」的总次数

当遇到一个词汇，这个词汇在词表的积极词汇分类中，那么特征1计数就会+1

优劣：

- 训练数据充足时不如原来的方法：将每一个单词出现的次数来当特征；
- 训练数据稀少时有着较好的效果，泛化能力更强。

垃圾邮件过滤：

垃圾邮件的特点：

- 会提到millions of (dollar) ((dollar) NN,NNN,NNN.NN)
- 邮件来源 用很多数字开头
- 主题都是大写
- HTML中的文字图片比很小
- 会提到 “百分之百保证”
- 声明可以从列表中删除

根据垃圾邮件的特点来设置特征

朴素贝叶斯用于其他文本分类任务

确定一段文字是用哪种语言：

基于字符N-grams的特征可以很好的完成识别任务

对多类型的一些语言进行训练是很重要的

- 例如美式英语包括非裔美式英语，英语还有很多类型比如印式英语

总结：朴素贝叶斯不那么朴素

速度快，存储消耗少

在小样本数据集上的效果很好

对无关属性具有鲁棒性

无关的属性会彼此抵消而不会影响结果

在一些属性重要性程度相当的领域中，表现很好

在一些情况下，尤其在数据很少的情况下，决策树会遭遇碎片化

若独立性假设成立，则为最优

可用做文本分类任务实验对比时的一个基准

- 其他分类器可以输出更好的结果



Part.04

二分类评估

评估二分类任务

考虑一个二分类任务

一个甜品销售经理，想知道人们对甜品的评价

发布一个有关该甜品的说说或者微博

- 正面 有关该甜品积极的评价
- 负面 所有其他的评价

评估二分类任务

2x2混淆矩阵(confusion matrix):

		<i>gold standard labels</i>		
		gold positive	gold negative	
<i>system output labels</i>	system positive	true positive	false positive	precision = $\frac{tp}{tp+fp}$
	system negative	false negative	true negative	
		recall = $\frac{tp}{tp+fn}$		accuracy = $\frac{tp+tn}{tp+fp+tn+fn}$

评估：准确率Accuracy

为什么不使用Accuracy作为评估标准？

假设有100万条微博评论

- 100条是有关对该甜品正面的评价
- 99.9万条是其他的(包括负面的，中性的，无关的等)

若我们对所有标记为“无关该甜品”类别的评论建立分类器，

- 那么准确率Accuracy是99.99%
- 因此我们要使用精度(Precision)和召回率(recall)

评估：精度Precision

所有"正确被检索的结果(TP)"占有所有"实际被检索到的(TP+FP)"的比例.

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

评估：召回率Recall

所有"正确被检索的结果(TP)"占有所有"应该检索到的结果(TP+FN)"的比例.

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

为什么要使用精度和召回率

避免先前 $\text{accuracy} = 99.99\%$ 情况的出现

强调 true positives

- 也就是找到想要找到的 items

评估: F-measure

F-measure 是精度和召回率的调和均值

$$F_{\beta} = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

通常使用F1-score作为度量标准, 即当 $\beta = 1$ 时

$$F_1 = \frac{2PR}{P + R}$$

开发集(Devset)和交叉验证(cross validation)




在训练集上学习， 在开发集上调整， 在测试集上验证

- 帮助避免过拟合
- 更保守的性能估计
- 如何划分训练集和开发集？

开发集(Devset)和交叉验证(cross validation)

交叉验证(cross validation):



多分类评估

		<i>gold labels</i>			
		urgent	normal	spam	
<i>system output</i>	urgent	8	10	1	precision_u = $\frac{8}{8+10+1}$
	normal	5	60	50	precision_n = $\frac{60}{5+60+50}$
	spam	3	30	200	precision_s = $\frac{200}{3+30+200}$
		recall_u = $\frac{8}{8+5+3}$	recall_n = $\frac{60}{10+60+30}$	recall_s = $\frac{200}{1+50+200}$	

多分类评估

如何在三分类任务中组合P和R为一个评估标准?

宏平均(macroaveraging):

- 计算每一类的性能评估
- 取所有类结果的均值

微平均(microaveraging):

- 收集所有类的结果到混淆矩阵中
- 从矩阵表中计算P和R

多分类评估

宏分类和微分类:

Class 1: Urgent

	true urgent	true not
system urgent	8	11
system not	8	340

$$\text{precision} = \frac{8}{8+11} = .42$$

Class 2: Normal

	true normal	true not
system normal	60	55
system not	40	212

$$\text{precision} = \frac{60}{60+55} = .52$$

Class 3: Spam

	true spam	true not
system spam	200	33
system not	51	83

$$\text{precision} = \frac{200}{200+33} = .86$$

Pooled

	true yes	true no
system yes	268	99
system no	99	635

$$\text{microaverage precision} = \frac{268}{268+99} = .73$$


$$\text{macroaverage precision} = \frac{.42+.52+.86}{3} = .60$$



Part.05

逻辑回归

逻辑回归



- 强大的监督模型
- 许多自然语言处理任务的基线方法
- 与神经网络有关
- 可以是二分类（两个类别）或多分类（两个以上类别）

逻辑回归概述

- **输入:**

带标签样本集合 $\{(d_i, y_i)\}_{i=1}^n$

其中每一个 d_i 表示一个文本，对于二分类任务， $y = 0$ 或 1

对于多分类任务， $y = 1, 2, \dots, m$

- **步骤:**

1. **特征表示** 中的分类实例
2. 使用 **分类函数** 计算 $\hat{y}$ 的 $P(\hat{y} | x)$
3. **损失函数** (用于学习)
4. **优化算法**

- **训练阶段:** 学习模型的 **参数** 以最小化 **损失函数**

- **测试阶段:** 在给定新输入 x 的情况下应用 **参数** 来预测类

判别模型

- 逻辑回归: $\hat{c} = \operatorname{argmax}_{c \in \mathcal{C}} P(c|d)$
- 朴素贝叶斯: $\hat{c} = \operatorname{argmax}_{c \in \mathcal{C}} P(d)P(c|d)$

猫：一种驯养的食肉哺乳动物，皮毛柔软，鼻子短，爪子可伸缩。

狗：一种驯养的食肉哺乳动物，有长鼻子、不可缩回的爪子和吠叫、嚎叫或哀嚎的声音。

1.特征表示

输入观测样本: $x^{(i)}$

特征向量: $x = [x_1, x_2, \dots, x_d]$

第 i 个输入样本的第 j 号特征: $x_j^{(i)}$

$x^{(i)}$ 就是对于 d_i 这个文章的特征向量

I love this movie! It's sweet,
but with satirical humor. The
dialogue is great and the
adventure scenes are fun...
It manages to be whimsical
and romantic while laughing
at the conventions of the
fairy tale genre. I would
recommend it to just about
anyone. I've seen it several
times, and I'm always happy
to see it again whenever I
have a friend who hasn't
seen it yet!

$x^{(i)}$



Bag of words

it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1

$[x_1, x_2, \dots, x_d]$

2.分类函数


给定：输入特征向量 $x = [x_1, x_2, \dots, x_d]$

输出： $P(y=1|x)$ 和 $P(y=0|x)$ (二分类任务)

需要一个函数 F : d 维实数空间 $\rightarrow [0,1]$ 区间

Sigmoid函数:

$$f(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}$$



权重(Weights)和偏置量(Biases)

- 哪些特征是最重要的，重要程度是多少？
- 给每一个特征学习一个权重组成权重向量，以及一个偏置项
- 权重：实数向量， $\mathbf{w} = [w_1, w_2, \dots, w_d]$ 对应 $\mathbf{x} = [x_1, x_2, \dots, x_d]$
- 偏置：标量截距 b
- 给定输入特征 $\mathbf{x}$ ，计算： $z = \mathbf{w} \cdot \mathbf{x} + b$ ($\mathbf{w}$ 与 $\mathbf{x}$ 做点积运算)
- 因此：Sigmoid函数：

$$f(\mathbf{w} \cdot \mathbf{x} + b) = \frac{e^{\mathbf{w} \cdot \mathbf{x} + b}}{1 + e^{\mathbf{w} \cdot \mathbf{x} + b}}$$

结合在一起


计算概率: $P(y = 1 | \mathbf{x}) = \frac{1}{1 + e^{-z}}$

$$P(y = 1) = \sigma(\mathbf{w} \cdot \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w} \cdot \mathbf{x} + b)}}$$

$$\begin{aligned} P(y = 0) &= 1 - \sigma(\mathbf{w} \cdot \mathbf{x} + b) \\ &= 1 - \frac{1}{1 + e^{-(\mathbf{w} \cdot \mathbf{x} + b)}} = \frac{e^{-(\mathbf{w} \cdot \mathbf{x} + b)}}{1 + e^{-(\mathbf{w} \cdot \mathbf{x} + b)}} \end{aligned}$$

决策边界: $\hat{y} = \begin{cases} 1 & \text{if } P(y = 1 | \mathbf{x}) > 0.5 \\ 0 & \text{otherwise} \end{cases}$

例子：文本分类



Var	Definition	Value
x_1	count(positive lexicon) $\in$ doc)	3
x_2	count(negative lexicon) $\in$ doc)	2
x_3	$\begin{cases} 1 & \text{if "no" } \in \text{ doc} \\ 0 & \text{otherwise} \end{cases}$	1
x_4	count(1st and 2nd pronouns $\in$ doc)	3
x_5	$\begin{cases} 1 & \text{if "!" } \in \text{ doc} \\ 0 & \text{otherwise} \end{cases}$	0
x_6	log(word count of doc)	$\ln(64) = 4.15$

这些值构成了特征向量!

例子：文本分类

Var	Definition	Value
x_1	count(positive lexicon) $\in$ doc)	3
x_2	count(negative lexicon) $\in$ doc)	2
x_3	$\begin{cases} 1 & \text{if "no"} \in \text{doc} \\ 0 & \text{otherwise} \end{cases}$	1
x_4	count(1st and 2nd pronouns $\in$ doc)	3
x_5	$\begin{cases} 1 & \text{if "!"} \in \text{doc} \\ 0 & \text{otherwise} \end{cases}$	0
x_6	log(word count of doc)	$\ln(64) = 4.15$

假设权重和偏执为： $w = [2.5, -5.0, -1.2, 0.5, 2.0, 0.7]$ $b = 0.1$

$$\begin{aligned}
 p(+|x) = P(Y = 1|x) &= \sigma(w \cdot x + b) \\
 &= \sigma([2.5, -5.0, -1.2, 0.5, 2.0, 0.7] \cdot [3, 2, 1, 3, 0, 4.15] + 0.1) \\
 &= \sigma(.805) \\
 &= 0.69
 \end{aligned} \tag{5.6}$$

$$\begin{aligned}
 p(-|x) = P(Y = 0|x) &= 1 - \sigma(w \cdot x + b) \\
 &= 0.31
 \end{aligned}$$

设计特征

- 最重要的准则：数据是关键！
- 语言学先验知识（例如：词性标签、句法分析树）
- 复杂特征组合

$$x_1 = \begin{cases} 1 & \text{if "Case}(w_i) = \text{Lower"} \\ 0 & \text{otherwise} \end{cases}$$
$$x_2 = \begin{cases} 1 & \text{if "w}_i \in \text{AcronymDict"} \\ 0 & \text{otherwise} \end{cases}$$
$$x_3 = \begin{cases} 1 & \text{if "w}_i = \text{St. \& Case}(w_{i-1}) = \text{Cap"} \\ 0 & \text{otherwise} \end{cases}$$

- 特征模板
- 稀疏表示：仅把出现过的特征哈希映射为索引
- 例子：三元语法（逻辑回归分类器） = 78 号特征
- 进阶内容：表示学习（后续课程会讲到！）

逻辑回归的优缺点

- 特征设计拥有更大的自由度
 - 不像朴素贝叶斯那样存在严苛的独立性假设
 - 对存在相关性的特征具有更强的鲁棒性（例如 “旧金山” 和 “波士顿” ）
—— 逻辑回归通常会比朴素贝叶斯效果更好
 - 甚至同一个特征可以出现两次！（为什么？）
- 相较于朴素贝叶斯，在小规模数据集上效果可能不佳
- 对训练得到的权重进行解释会比较困难

3.如何训练一个逻辑回归模型

- 我们有了分类函数之后该如何分配权重和偏执量？
- 目标：让预测标签 $\hat{y}$ 尽可能地贴近真实标签 y
 - 预测值 $y^{\wedge}$ 与真实值 y 之间的距离度量 / 损失函数： $L(\hat{y}, y)$
 - 通过优化算法去更新权重参数

损失函数

- 假设 $\hat{y} = \sigma(w \cdot x + b)$
- 损失函数 $L(\hat{y}, y)$: 度量预测值 $\hat{y}$ 与真实值 y 之间的差距, 但它该采用什么形式呢?
- **条件极大似然估计:**
 - 选取权重 w 和偏置 b , 使输入 x 对应的真实值 y 的对数条件概率 $\log P(y|x)$ 最大化
 - 和 N 元语法的思路类似!
 - N 元语法中我们选取参数, 在给定语料库的条件下最大化 $\log P(w_t | w_{t-n}, \dots, w_{t-1})$

交叉熵损失的一个实例

- 假设一个数据点 (x, y) 的二分类任务
- 分类器概率: $P(y | x) = \hat{y}^y (1 - \hat{y})^{1-y}$ (简化写法)
- 对数概率: $\log P(y | x) = \log[\hat{y}^y (1 - \hat{y})^{1-y}]$
 $= y \log \hat{y} + (1 - y) \log(1 - \hat{y})$ (使该式最大化)
- 损失: $-\log P(y | x) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$ (使该式最小化)
 - $y = 1 \Rightarrow -\log \hat{y}$ 以及 $y = 0 \Rightarrow -\log(1 - \hat{y})$

交叉熵损失

对于一个数据点 $(x^{(i)}, y^{(i)})$

分类器概率: $\prod_{i=1}^n P(y | x) = \prod_{i=1}^n \hat{y}^y (1 - \hat{y})^{1-y}$

损失: $-\log \prod_{i=1}^n P(y | x) = - \sum_{i=1}^n \log P(y|x)$

$$L_{CE} = - \sum_{i=1}^n [y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

例子：计算交叉熵损失

Var	Definition	Value in Fig. 5.2
x_1	count(positive lexicon) $\in$ doc)	3
x_2	count(negative lexicon) $\in$ doc)	2
x_3	$\begin{cases} 1 & \text{if "no"} \in \text{doc} \\ 0 & \text{otherwise} \end{cases}$	1
x_4	count(1st and 2nd pronouns $\in$ doc)	3
x_5	$\begin{cases} 1 & \text{if "!"} \in \text{doc} \\ 0 & \text{otherwise} \end{cases}$	0
x_6	log(word count of doc)	$\ln(64) = 4.15$

- 假设权重和偏执量为 $w = [2.5, -5.0, -1.2, 0.5, 2.0, 0.7]$ $b = 0.1$
- 如果 $y = 1$ (正类), $L_{\text{CE}} = -\log(0.69) = 0.37$
- 如果 $y = 0$ (负类), $L_{\text{CE}} = -\log(0.31) = 1.17$

交叉熵损失的性质



- $$L_{CE} = - \sum_{i=1}^n [y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})]$$

- 它的取值范围是?

A) 0 to ∞

B) $-\infty$ to ∞

C) $-\infty$ to 0

D) 1 to ∞

交叉熵损失的性质

- $$L_{CE} = - \sum_{i=1}^n [y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})]$$
- 取值范围从0（完美的预测） 到 ∞
- 值越低，分类效果越好
- 数据中真实分布 $P(y|x)$ 与预测分布 $P(\hat{y}|x)$ 之间的交叉熵

4.优化损失函数的算法


- 我们有了分类函数和损失函数之后该如何找到最佳的 w 和 b ?

$$\theta = [w; b]$$

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n L_{CE}(y^{(i)}, x^{(i)}; \theta)$$

- 梯度下降法：
 - 找出最陡坡度的方向
 - 向相反方向移动


梯度下降



$$\theta^{t+1} = \theta^t - \eta \frac{d}{d\theta} f(x; \theta)$$

逻辑回归的梯度下降


- 逻辑回归的交叉熵损失是凸的（即具有只有一个全局最小值）
- 没有陷入困境的局部最小值
- 深度神经网络并不那么容易
- 非凸形




学习率 η (Learning Rate)

- 参数更新公式: $\theta^{t+1} = \theta^t - \eta \frac{d}{d\theta} f(x; \theta)$

- 沿坡度移动的幅度
- 更高/更快的学习率=参数更新量更大



学习率过小: 收敛速度非常缓慢




学习率过大: 发生过冲, 甚至出现发散

向量权重的梯度下降

- 在逻辑回归中：权重 w 是一个向量
- 将斜率表示为每个权重损失的偏导数：

$$\nabla_{\theta} L(f(x; \theta), y) = \begin{bmatrix} \frac{\partial}{\partial w_1} L(f(x; \theta), y) \\ \frac{\partial}{\partial w_2} L(f(x; \theta), y) \\ \vdots \\ \frac{\partial}{\partial w_n} L(f(x; \theta), y) \end{bmatrix}$$

- 参数更新公式： $\theta^{(t+1)} = \theta^t - \eta \nabla L(f(x; \theta), y)$



逻辑回归的梯度

- $$L_{CE} = - \sum_{i=1}^n [y^{(i)} \log \sigma(\mathbf{w} \cdot \mathbf{x}^{(i)} + b) + (1 - y^{(i)}) \log(1 - \sigma(\mathbf{w} \cdot \mathbf{x}^{(i)} + b))]$$

- 梯度
$$\frac{dL_{CE}(\mathbf{w}, b)}{dw_j} = \sum_{i=1}^n \underbrace{[\sigma(\mathbf{w} \cdot \mathbf{x}^{(i)} + b) - y^{(i)}]}_{\text{真实值 } y \text{ 与预测值之间的差值}} x_j^{(i)}$$

输入特征值

- $$\frac{dL_{CE}(\mathbf{w}, b)}{db} = \sum_{i=1}^n [\sigma(\mathbf{w} \cdot \mathbf{x}^{(i)} + b) - y^{(i)}]$$

随机梯度下降(Stochastic Gradient Descent)

- 在线优化
- 计算损失并在每个训练示例后最小化

function STOCHASTIC GRADIENT DESCENT($L()$, $f()$, x , y) **returns** θ

where: L is the loss function

f is a function parameterized by θ

x is the set of training inputs $x^{(1)}, x^{(2)}, \dots, x^{(n)}$

y is the set of training outputs (labels) $y^{(1)}, y^{(2)}, \dots, y^{(n)}$

$\theta \leftarrow 0$

repeat til done # see caption

For each training tuple $(x^{(i)}, y^{(i)})$ (in random order)

1. Optional (for reporting): # How are we doing on this tuple?

 Compute $\hat{y}^{(i)} = f(x^{(i)}; \theta)$ # What is our estimated output $\hat{y}$?

逐样本损失 $\longrightarrow$ Compute the loss $L(\hat{y}^{(i)}, y^{(i)})$ # How far off is $\hat{y}^{(i)}$ from the true output $y^{(i)}$?


2. $g \leftarrow \nabla_{\theta} L(f(x^{(i)}; \theta), y^{(i)})$ # How should we move θ to maximize loss?

3. $\theta \leftarrow \theta - \eta g$ # Go the other way instead

return θ

随机梯度下降(Stochastic Gradient Descent)

- 在线优化
- 计算损失并在每个训练示例后最小化



谢谢



信息工程学院
(人工智能学院)